Satisfaction des passagers : où investir, qui accueillir

Rush 3 – Bootcamp Data · Rapport à la directrice de l'Expérience Client

Groupe : Sophie Tandé, Myriam Yavo, Stève Fanté

Synthèse pour la directrice

Nous avons analysé l'enquête post-vol de **103 904 passagers** : **56,7 %** se disent neutres ou insatisfaits. Ce rapport répond à vos deux questions : où investir, et qui accueillir à l'arrivée. Il précise aussi à quelles conditions ce repérage respecte la protection des données.

1. Où investir le budget

- **Le parcours numérique d'abord.** À profil égal, un point de plus sur l'**embarquement en ligne** multiplie par 2,5 les chances d'être satisfait ; un point de plus sur le **wifi à bord**, par 2,3. Ce sont aussi deux des services les moins bien notés (3,3 et 2,8 sur 5).
- **Ensuite le service humain** : service à bord, enregistrement et réservation en ligne (×1,4 à ×1,5 par point), puis propreté et espace pour les jambes.
- **Deux publics à part** : les seniors (65 ans et plus) sont insatisfaits à 81,6 % et notent nettement moins bien les bagages, le service en vol et l'espace pour les jambes. Les moins de 18 ans notent mal l'embarquement en ligne.
- Ce sont des **liens observés**, pas des preuves : nous recommandons de **tester sur quelques lignes**, en les comparant à des lignes témoins, avant de généraliser.

2. Qui accueillir à l'arrivée

92,4 % – des passagers signalés sont bien neutres ou insatisfaits (test final)

5 239 € – de gain net pour 1 000 passagers adultes, en abordant 1 passager sur 10

0 – mineur ciblé : les moins de 18 ans sont exclus du dispositif

- Notre modèle (une **forêt aléatoire**, c'est-à-dire un ensemble d'arbres de décision) estime le risque de chaque passager adulte à partir de six informations connues à l'atterrissage : la classe, la fidélité, l'âge, la catégorie de vol et les deux retards (au départ et à l'arrivée). Les équipes abordent les 10 % les plus à risque.
- Il fait **nettement mieux qu'une règle simple** sans modèle (« clients non fidèles en Éco d'abord, puis les plus retardés ») : **+714 €** pour 1 000 passagers (92,4 % de bons signalements contre 85,3 %), et plus de trois fois mieux que le hasard.
- **Ce que coûtent ses erreurs** : sur 100 passagers abordés, environ 92 sont insatisfaits et 8 satisfaits (≈ 300 € d'approches inutiles pour 1 000 passagers). Avec 1 passager abordé sur 10, **83 % des insatisfaits ne sont pas abordés** : l'accueil ciblé complète l'amélioration du service, il ne la remplace pas.

3. Nos recommandations

1. Investir d'abord dans l'embarquement en ligne et le wifi, en pilote avec des lignes témoins ; puis dans le service aux seniors (bagages, service à bord).
2. Déployer l'accueil ciblé des adultes avec le modèle. Les agents ne voient qu'un « accueil prioritaire » et la raison (ex. retard), jamais un score, l'âge ni un profil.
3. Avant le lancement : analyse d'impact (AIPD), information des passagers avec droit d'opposition, et maintien de l'exclusion des mineurs.

1. Les données et notre démarche

1.1 Deux fichiers, deux rôles

Chaque ligne décrit un passager : son profil (type de client, âge, classe), son vol (catégorie de vol, retards au départ et à l'arrivée), ses notes de 1 à 5 sur 14 services, et sa réponse « satisfait » ou « neutre ou insatisfait ».

- **Premier fichier** (`train.csv`, **103 904 passagers**) : il sert à toute l'analyse et à l'entraînement des modèles.
- **Second fichier** (`test.csv`, **25 976 passagers**, « le mois prochain ») : il sert à la fin, pour mesurer la performance du modèle déjà choisi.

1.2 Nos choix de départ

Choix	Ce que nous avons fait	Pourquoi
Mineurs	Les passagers de moins de 18 ans ne sont **jamais ciblés** : ils sont exclus du modèle (95 973 adultes pour l'entraînement, 24 060 pour le test) **MAIS** pour la satisfaction, ils sont acceptés car accompagnés de leur représentant légal (parent)	Protection renforcée des enfants : un mineur ne doit pas être abordé par du personnel sur la base d'un profilage
Catégorie de vol	Court (≤ 700 miles), moyen (701 à 3 000), long (> 3 000)	Plus parlant pour les équipes qu'une distance brute
Tranches d'âge	Enfant (< 12 ans), ado (12-17), adulte (18-64), senior (65 et +)	Comparer les attentes selon l'âge ; « ado » regroupe tous les autres mineurs
Variables du modèle	Fidélité, âge, classe, catégorie de vol, retard au départ, retard à l'arrivée	Seules informations connues à l'atterrissage (§4.1)
Capacité	Les équipes abordent les 10 % de passagers au risque le plus élevé	Contrainte donnée par la directrice

1.3 Préparation des données

Constat	Décision	Volume
Une note de 0 signifie « pas de réponse » (énoncé)	Traitée comme une valeur manquante, exclue des moyennes	15 932 notes
Colonnes techniques : la première colonne (numéro de ligne) et l'identifiant	La première colonne sert d'index, l'identifiant est retiré ; le sexe n'est pas utilisé pour repérer les passagers	2 colonnes
Retards extrêmes (jusqu'à 26 h)	Conservés : ce sont de vrais vols, et précisément ceux qu'il faut cibler	247 vols > 5 h de retard

Ne pas noter un service n'est pas neutre : seuls 0,3 % des passagers qui n'ont pas noté le wifi sont insatisfaits, contre 58,4 % des autres. C'est pourquoi les non-réponses sont gardées comme manquantes plutôt que remplacées par une moyenne.

2. Qui sont les passagers neutres ou insatisfaits ?

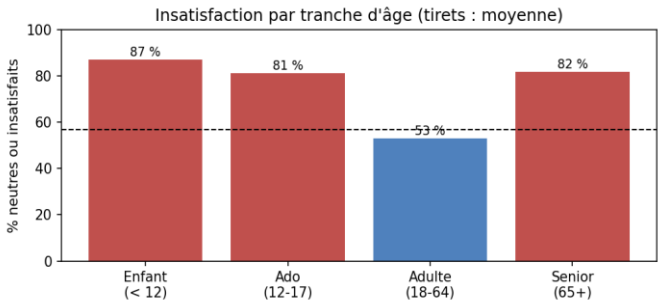


Figure 1 – Insatisfaction par tranche d'âge

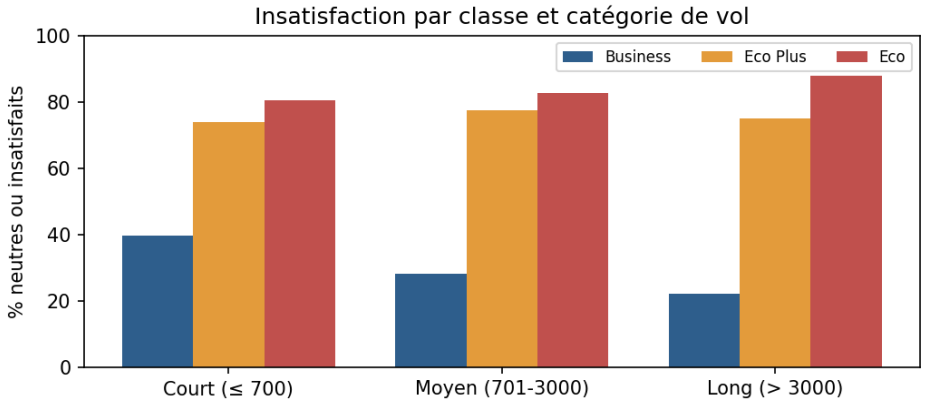


Figure 2 – Insatisfaction par classe et catégorie de vol

- **La classe est le premier marqueur.** En Business, l'insatisfaction baisse avec la distance (39,6 % en court-courrier, 22,1 % en long-courrier). En Éco, elle reste au-dessus de 80 % quelle que soit la distance.
- **L'âge dessine une courbe en U** : les adultes de 18 à 64 ans sont insatisfaits à 53,0 %, contre 87,1 % pour les enfants, 81,2 % pour les ados et 81,6 % pour les seniors.
- **La fidélité compte** : 76,3 % d'insatisfaits chez les clients non fidèles, contre 52,3 % chez les fidèles. Le sexe ne fait presque pas de différence (57,3 % contre 56,1 %).

2.1 Ce que chaque public reproche (notes moyennes sur 5)

Service	Enfant	Ado	Adulte	Senior	Tous	Lecture
Embarquement en ligne	2,69	2,78	3,38	3,20	3,33	Les jeunes le notent nettement plus mal
Wifi à bord	2,59	2,67	2,84	2,62	2,81	Le service le moins bien noté, pour tous
Confort du siège	2,96	3,03	3,48	3,35	3,44	Plus faible chez les jeunes
Bagages	3,67	3,68	3,65	3,28	3,63	**Point faible des seniors**
Service en vol	3,69	3,70	3,65	3,30	3,64	**Point faible des seniors**
Espace pour les jambes	3,20	3,21	3,40	2,99	3,37	**Point faible des seniors**

Attention, ce sont des liens observés. Les adultes de 18 à 64 ans voyagent plus souvent pour le travail, en Business et sur de longues distances : une partie de l'écart attribué à l'âge vient donc de la classe et du motif du voyage. La partie 3 isole l'effet propre de chaque facteur.

3. Les facteurs de la satisfaction

3.1 Méthode : séparer l'effet propre de chaque facteur

Comparer des moyennes ne suffit pas, car plusieurs effets se mélangent. Par exemple, les passagers en Business donnent de meilleures notes à **tous** les services et sont aussi plus souvent satisfaits : impossible de savoir si c'est le wifi, le siège ou simplement la classe qui fait la différence.

Pour démêler ces effets, nous avons utilisé une **régression logistique** : un modèle qui prend en compte toutes les informations en même temps (profil du passager, vol, 14 notes de service, et le fait d'avoir noté ou non chaque service). Il mesure l'effet d'un seul service en comparant des passagers **identiques sur tout le reste** : même classe, même âge, même vol, mêmes autres notes. C'est le sens de l'expression « toutes choses égales par ailleurs ».

Ce modèle est fiable : si l'on prend au hasard un passager satisfait et un passager insatisfait, il reconnaît le satisfait dans **96,5 %** des cas (AUC de 0,965 ; 1 = parfait, 0,5 = hasard). Il sert à **comprendre**, pas à prévoir à l'atterrissage : il utilise les notes de l'enquête, qui ne sont connues qu'après le vol.

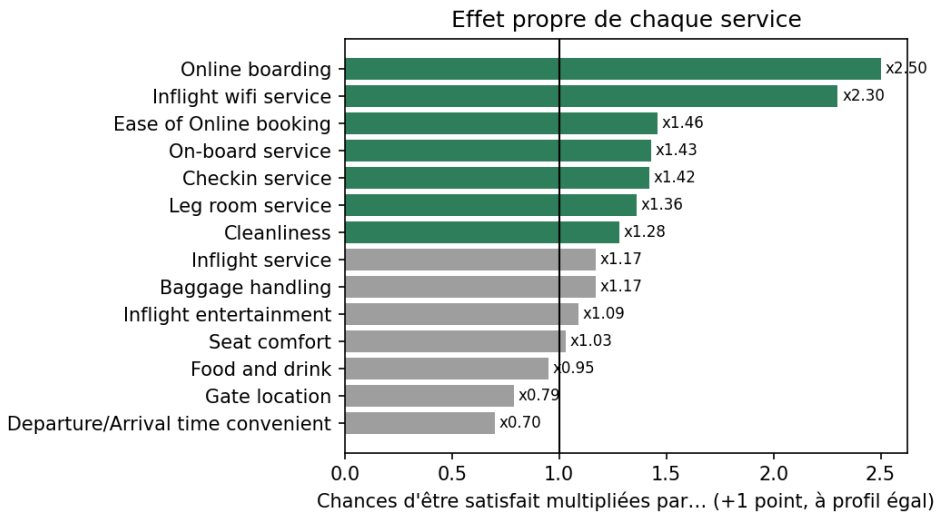


Figure 3 – Effet propre d'un point de note sur les chances d'être satisfait (1 = aucun effet ; vert = effet notable)

3.2 Écart brut et effet propre ne disent pas la même chose

Service	Écart brut*	Effet propre	Ce qu'il faut en retenir
Embarquement en ligne	+59 pts	×2,50	Le levier le plus fort, brut comme ajusté
Wifi à bord	+47 pts	×2,30	Second levier, et le service le moins bien noté
Réservation en ligne	+29 pts	×1,46	Parcours numérique, cohérent avec les deux premiers
Service à bord · enregistrement	+31 · +17 pts	×1,43 · ×1,42	Formation et organisation des équipes
Espace pour les jambes · propreté	+34 · +26 pts	×1,36 · ×1,28	Effet réel ; l'espace est coûteux (cabine)
Divertissement · confort du siège	+41 · +38 pts	×1,09 · ×1,03	**Piège** : fort écart brut, presque aucun effet propre
Restauration	+19 pts	×0,95	Pas d'effet propre mesurable
Porte d'embarquement · horaires	+4 · −5 pts	×0,79 · ×0,70	Peu actionnables (aéroport, programme de vols)

* Écart de taux de satisfaits entre les passagers qui donnent 4-5 et ceux qui donnent 1-3 au service.

3.3 Associé, causal, actionnable : le statut de chaque facteur

Un facteur associé à la satisfaction n'en est pas forcément la cause, et la compagnie ne peut pas agir sur tous. Le tableau rend la distinction explicite pour chaque facteur cité.

Facteur	Associé ?	Cause plausible ?	Actionnable ?	Recommandation
Embarquement en ligne	Oui, fort, même à profil égal	Plausible : une étape stressante. Mais un passager déjà mécontent peut tout noter plus sévèrement	Oui	Budget prioritaire, en pilote avec lignes témoins

Facteur	Associé ?	Cause plausible ?	Actionnable ?	Recommandation
Wifi à bord	Oui, fort, même à profil égal	Plausible ; mesure imparfaite (non-réponses de passagers presque tous satisfaits)	Oui	Budget prioritaire, en pilote
Réservation en ligne, enregistrement, service à bord	Oui, modérément	Plausible	Oui	Second rang : ergonomie, formation
Bagages, service en vol, espace (pour les seniors)	Oui : notes plus basses et 81,6 % d'insatisfaits	Plausible ; à confirmer à classe égale	Oui	Offre d'assistance seniors à tester
Divertissement, confort du siège	Oui en brut, presque plus à profil égal	Peu probable : effet porté par la classe et les autres services	Oui	**Ne pas prioriser**
Retard à l'arrivée	Oui (×0,78 par heure)	Oui, très probable	En partie (opérations)	Signal pour l'accueil ciblé
Classe Éco / Éco Plus	Oui (×0,42 / ×0,33)	En partie : le produit diffère	Indirectement	Améliorer l'Éco sur les leviers ci-dessus
Client non fidèle	Oui, très fort (×0,06)	**Causalité probablement inversée** : on devient fidèle parce qu'on est satisfait	Non directement	Ne pas « acheter » de fidélité
Motif personnel	Oui, très fort (×0,04)	Non : un profil, pas une action	Non	Adapter l'offre loisirs
Âge	Oui en brut (courbe en U)	Non : l'âge ne cause rien, il signale des attentes différentes	Non	Cibler des services, pas des âges

3.4 Limites de cette analyse

- **Données d'enquête, pas d'expérience** : aucun résultat ne prouve une cause. Seul un pilote avec des lignes témoins le peut.
- **Biais de réponse** : seuls les répondants sont observés ; les autres passagers peuvent avoir un autre avis.
- **Cible regroupée** : « neutre » et « insatisfait » sont confondus ; un passager neutre n'a pas forcément l'intention de partir.
- **Effet de halo** : un passager mécontent tend à noter tous les services plus bas, ce qui gonfle les liens entre notes et satisfaction.

4. Repérer à l'atterrissage les passagers probablement insatisfaits

4.1 Ce que la compagnie sait quand l'avion atterrit

Le modèle apprend sur les vols passés. Mais au moment où l'avion atterrit, le passager n'a pas encore répondu au questionnaire, et la plupart n'y répondront jamais. Le modèle ne peut donc utiliser que les informations déjà connues à l'atterrissage, et il s'applique à **tous** les passagers adultes qui arrivent.

Variable	Connue à l'atterrissage ?	Utilisée ?	Justification
Classe, catégorie de vol	Oui (réservation)	Oui	Donnée de réservation, non sensible

Variable	Connue à l'atterrissage ?	Utilisée ?	Justification
Retards au départ et à l'arrivée	Oui (opérations)	Oui	Donnée du vol, pas de la personne
Client fidèle ou non	Oui (programme de fidélité)	Oui	Relation commerciale existante
Âge	Oui (réservation)	Oui, sous conditions	Apporte 485 € pour 1 000 passagers (§4.3) ; jamais montré aux agents
Motif du voyage	**Non fiable** : rarement déclaré à la réservation	Non	Ne pas le déduire d'autres données personnelles
Sexe	Oui	**Non**	Aucun lien utile (57,3 % contre 56,1 %) ; risque de discrimination
14 notes de service	**Non** : l'enquête arrive après	**Non**	Les utiliser gonflerait artificiellement la performance (fuite de données)

4.2 Approches comparées

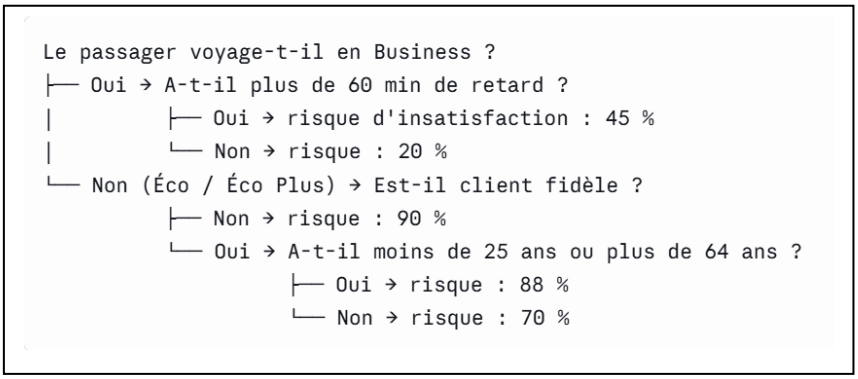
Les équipes n'abordent qu'**un passager sur dix** : chaque méthode classe les passagers du plus au moins risqué, et l'on aborde les 10 % du haut. Selon les estimations de la directrice, aborder un insatisfait rapporte **100 €** en moyenne (1 sur 3 partirait, soit 600 € perdus, et l'approche en ramène la moitié), soit **+60 €** net. Aborder un satisfait coûte **40 €**.

Approche (validation croisée, adultes, 10 % abordés)	AUC	Précision	Gain / 1 000 pass.
Hasard	0,50	54,7 %	1 468 €
Règle simple : non fidèles en Éco / Éco Plus, puis Éco, puis les plus retardés	0,78	86,6 %	4 662 €
Régression logistique (6 variables)	0,80	86,6 %	4 658 €
Forêt aléatoire (6 variables) – modèle retenu	0,83	92,5 %	5 250 €
Forêt aléatoire sans l'âge (5 variables)	0,81	87,7 %	4 765 €

AUC : capacité à classer un insatisfait avant un satisfait. Précision : part d'insatisfaits parmi les passagers abordés. Forêt aléatoire : 100 arbres de profondeur 10 au maximum.

Un arbre de décision : une suite de questions

Un arbre de décision ressemble au jeu « Qui est-ce ? » : il pose des questions par oui ou non, l'une après l'autre, jusqu'à arriver à une réponse. Voici un exemple avec vos variables.
Un foret de décision est ensemble d'arbre de décision contribuant



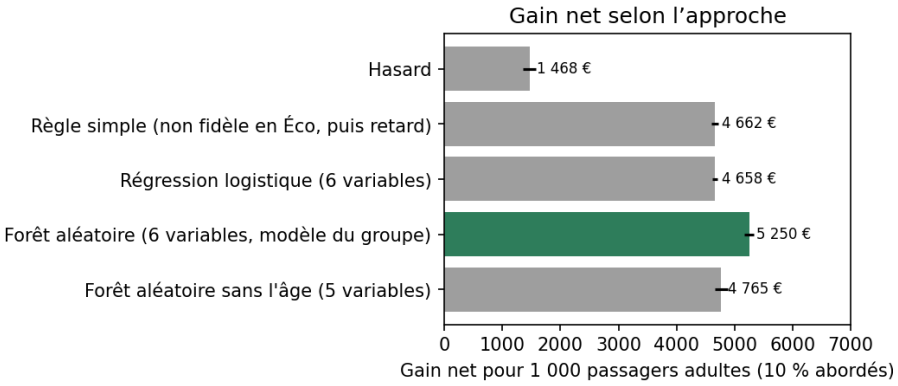


Figure 4 – Gain net pour 1 000 passagers adultes (barre = écart-type entre les 5 plis)

4.3 Le modèle retenu, et pourquoi

Nous retenons la **forêt aléatoire**. C'est la seule approche qui fait nettement mieux que la règle simple : **+588 €** pour 1 000 passagers en validation croisée, un écart bien supérieur à la variation entre plis (moins de 120 €). Elle capte une interaction que la régression logistique ignore : l'âge n'agit pas en ligne droite, il dessine une courbe en U (figure 1). Sans l'âge, la forêt perd **485 €** pour 1 000 passagers. C'est le prix à mettre en face de l'usage de cette donnée (§6).

Ce que fait le modèle, en une phrase pour le comité de direction : *« il repère surtout les passagers de classe Éco, les clients non fidèles, les plus jeunes et les plus âgés, et ceux qui ont subi un retard »*. Les variables qu'il utilise le plus sont la classe (66 % de l'importance totale), l'âge (14 %), la fidélité (10 %), les retards (6 %) et la catégorie de vol (4 %).

4.4 Résultat sur les « passagers du mois prochain »

Le modèle a été appliqué aux 24 060 passagers adultes du second fichier (54,0 % de neutres ou insatisfaits). **Résultats : AUC 0,828, 2 223 vrais mécontents sur 2 406 passagers abordés (92,4 %) et 5 239 € de gain net pour 1 000 passagers. La règle simple obtient 85,3 % et 4 525 €.** Notre première version, faite dans le classeur, donnait 2 219 sur 2 406 (92,2 %) ; le code la reproduit à 4 passagers près.

Pour 1 000 passagers adultes (test final)	Nombre	Coût ou valeur
Abordés et effectivement insatisfaits	≈ 92	≈ 9 240 € de revenus futurs préservés en moyenne
Abordés alors que satisfaits (faux positifs)	≈ 8	≈ 300 € d'approches inutiles
Coût total des 100 approches	100	4 000 €
Insatisfaits non abordés (faux négatifs)	≈ 448	Limite de capacité, pas du modèle

Le modèle se trompe surtout dans un sens. Un satisfait abordé ne coûte que 40 € et reçoit une attention plutôt bien perçue. En revanche, la grande majorité des insatisfaits reste hors de portée tant que la capacité est de 1 passager sur 10.

5. Recommandations

1. **Budget** : embarquement en ligne et wifi en priorité, puis service à bord, enregistrement et réservation en ligne. Lancer chaque investissement en **pilote** sur quelques lignes, avec des lignes témoins.
2. **Seniors** : tester une offre d'assistance (bagages, service en vol, sièges avec plus d'espace) et mesurer son effet sur leur satisfaction.
3. **Accueil ciblé** : déployer le modèle pour les adultes à 10 % de capacité. Mesurer le taux de retour réel des passagers abordés pour remplacer les hypothèses de 1 sur 3 et 1 sur 2.
4. **Suivi** : réentraîner le modèle chaque trimestre ; séparer « neutre » et « insatisfait » dans l'enquête ; collecter le motif du voyage à la réservation si les passagers l'acceptent.

6. Protection des données

L'enquête a été collectée pour **mesurer la satisfaction**. Signaler des passagers arrivants au personnel, dont la plupart n'ont jamais répondu, est une **nouvelle finalité**. Il faut distinguer deux usages : les réponses à l'enquête servent seulement à **entraîner** le modèle, tandis que celui-ci s'applique ensuite aux **données de réservation et d'exploitation** de tous les passagers adultes. C'est un profilage au sens du RGPD (art. 4.4).

6.1 Conditions pour que cet usage soit acceptable

Condition	Mise en œuvre proposée
Finalité compatible (art. 5.1.b et 6.4)	Le lien avec la finalité d'origine (améliorer l'expérience passager) est étroit, et l'effet est favorable au passager (un geste commercial). À documenter.
Base légale (art. 6.1.f)	Intérêt légitime de la compagnie, avec une mise en balance écrite des intérêts des passagers.
Analyse d'impact – AIPD (art. 35)	Profilage systématique de tous les passagers : AIPD avec le DPO avant le lancement.
Information et opposition (art. 13, 14 et 21)	Mention dans les conditions de transport et l'application ; opposition simple depuis l'espace client.
Pas de décision défavorable automatisée (art. 22)	Le modèle propose, l'agent décide ; aucun passager n'est pénalisé, et un passager non signalé garde accès au service client normal.
Conservation limitée	Signalement supprimé dans les 24 h ; aucun historique individuel de « passager mécontent ».

6.2 Les enfants : exclus du ciblage

7,6 % des répondants ont moins de 18 ans, et les enfants bénéficient d'une protection particulière (considérant 38 du RGPD). **Notre dispositif ne cible aucun mineur** : ils sont retirés de l'entraînement et de l'application du modèle. Cette exclusion a un coût, puisque les moins de 18 ans sont insatisfaits à 83,6 %. Leur satisfaction passe donc par les **adultes qui les accompagnent**, qui peuvent eux-mêmes être signalés, et par l'amélioration des services. Les réponses de mineurs à l'enquête ne devraient être utilisées qu'avec un accord parental.

6.3 Chaque information utilisée est-elle acceptable pour ce but ?

Information	Acceptable ?	Raison
Retards du vol, catégorie de vol, classe	Oui	Données de réservation et d'exploitation, nécessaires et non sensibles
Client fidèle ou non	Oui, avec information	Relation commerciale existante
Âge	**Oui, sous conditions**	Pas une donnée sensible, et un vrai gain (485 € pour 1 000 passagers). Mais c'est un critère protégé contre la discrimination : utilisation à justifier dans l'AIPD, jamais affichée aux agents, et contrôle que les seniors abordés le sont pour leur bénéfice
Sexe, motif du voyage	**Non**	Inutile pour le premier ; non fiable et intrusif pour le second
Réponses à l'enquête	**Non** à l'atterrissage	Inconnues à ce moment, et collectées pour un autre but

6.4 Ce que l'agent voit d'un passager signalé

Écran proposé : nom, siège, mention « **Accueil prioritaire** », une raison factuelle (« vol arrivé avec 2 h 10 de retard ») et le geste commercial disponible. **Jamais** : de score ou de probabilité d'insatisfaction, de mention « à risque », d'âge, ni de lien avec une réponse à l'enquête.

Analyse de risques réalisée dans le cadre d'un exercice ; elle ne remplace pas l'avis du DPO de la compagnie.